



Факультет социально-экономических и
компьютерных наук

Кафедра информационных
технологий в бизнесе

Пермь
2025

Задание 1

Подготовка данных (загрузка и визуализация данных,
импутирование данных и интерполяция)



Базовая часть (полное выполнение — 8 баллов)

- 1) Скачать файлы данных или подобрать свои (https://disk.yandex.ru/d/ADpRgSJX_uJ4qQ)
- 2) Создать программу на языке R/Python выполняющую
 - загрузку выбранного набора данных
 - необходимые преобразования для построения графиков (преобразования типов данных/обозначений и т.п.)
 - построить следующие типы диаграмм (при построении графиков использовать не менее 1000 значений, подписать оси, для линейных диаграмм указать направление их изменения, построить клетки): а) линейная диаграмма; б) столбчатая диаграмма; в) круговая диаграмма; г) скрипичная диаграмма
- 3) Изучить предметную область к которой относятся данные и интерпретировать полученные зависимости с опорой на полученные зависимости (провести качественный анализ данных)
- 4) Рассмотреть методы заполнения пропущенных значений на не менее чем 20 значениях
 - проредить значения оставив только каждое второе
 - заполнить прореженные значения средними и медианными значениями ряда
 - заполнить прореженные значения средним 3-х предыдущих известных значений ряда
 - применить для заполнения пропусков метод Лагранжа
 - заполнить прореженные значения с использованием метода кубических сплайнов
 - построить графики, нанести на них найденные и реальные (отброшенные значения)
- 5) Посчитать разницу между реальными (удаленными) и восстановленными значениями (одним из методов) на предмет недостоверных значений
 - методом 2/3 сигма
 - построить box-plot/скрипичные диаграммы, определить выбросы

Дополнительная часть:

+1 балл

- 1) использовать свой файл данных вместо предложенных преподавателем (без повторов между одногруппниками на потоке);
- 2) дополнительно построить один из следующих типов графиков: трехкомпонентная диаграмма, карта, лица Чернова, поверхность (3D график), график с выделенными областями, лепестковые диаграммы

+2 балла

дополнительно к (+1 балл)

- 1) Создайте искусственные пропуски по конкретной схеме: например, удалите значения для целого выходного дня, удалите 6 часов подряд, имитируя сбой датчика и т.п.
- 2) Рассчитайте метрики ошибки между реальными (удаленными) значениями и значениями, заполненными каждым из методов (среднее, медиана, Лагранж, сплайны). Используйте как минимум две дополнительные метрики: MAE, RMSE, MAPE, MASE



Файлы данных для выполнения работы (https://disk.yandex.ru/d/ADpRgSJX_uJ4qQ)

- DataSet3_1 – Данные о частоте и потребляемой мощности электрической энергии офисным зданием (регулярный временной ряд)
- DataSet3_2 – данные о курсе доллара и стоимости барреля нефти (нерегулярный временной ряд).

Ссылка на данные:




Полезные ссылки по R

Вопросы-ответы

- 1) <https://stackoverflow.com>
- 2) <https://www.r-bloggers.com>

Интерпритатор R библиотеки и среда разработки

- 1) <https://www.r-project.org>
- 2) <https://cran.r-project.org/mirrors.html>
- 3) <https://www.rstudio.com>





Где брать количественные данные для исследования

➡ [Kaggle](#) — библиотека открытых данных, где есть поисковая система и большое количество разных датасетов. Датасеты можно отфильтровать по темам, качеству обработки, формату файлов и типу лицензии, по которой её добавили на сайт. Библиотека работает на английском языке. Для перевода можно использовать функцию «Перевести страницу» в Яндекс Браузере или расширение DeepL.

➡ [Awesome data](#) на GitHub. В этом хранилище хранится две сотни датасетов, сгруппированных по темам. Подборку составляют и обновляют сами пользователи GitHub, добавляя туда данные из открытых источников. Если с датасетом что-то не так, пользователи сообщают об этом в комментариях, и такой набор данных помечается жёлтым значком. Это значит, что с ними могут быть сложности — например, не хватает части заполненных полей или некоторые данные перемешаны.

➡ [Google Dataset Search](#) — специализированный сервис для удобного поиска датасетов. Инструмент позволяет находить и фильтровать результаты по типу данных (например, таблицы, изображения, текст), а также предоставляет полное описание баз данных, включая дату создания, размер, краткое описание и количество научных статей, в которых датасет был использован.

➡ [Harvard Dataverse](#) — онлайн-хранилище данных, где можно делиться, сохранять, цитировать, изучать и анализировать исследовательские данные. Открыто для всех исследователей и содержит 188 тысяч датасетов.

➡ Открытые данные по интернет цензуре <https://explorer.ooni.org/ru>

➡ Данные предприятия/лаборатории на которых вы работаете



Открытые данные в России:


- ➡ [Портал открытых данных Правительства Москвы](#) — официальный ресурс, где публикуются данные городских служб Москвы: транспорт, образование, экология, ЖКХ и другие направления.
- ➡ [Система классификаторов и открытых данных Санкт-Петербурга](#) — портал администрации Санкт-Петербурга с набором городских данных по инфраструктуре, транспорту, социальным услугам и муниципальной статистике.
- ➡ [ЕМИСС](#) — Единая межведомственная информационно-статистическая система, собирающая официальную государственную статистику России из разных ведомств.
- ➡ [Хаб открытых данных](#) — агрегатор, который собирает и систематизирует открытые наборы данных из разных российских источников госсектора, НКО, коммерческих компаний, но это не государственный ресурс.
- ➡ [СберИндекс](#) — аналитическая платформа Сбера, где публикуются агрегированные данные об экономической активности, потреблении, мобильности и других макроэкономических показателях.
- ➡ [Исследования Яндекса](#) — результаты исследований на основе данных сервисов Яндекса, в которых авторы рассказывают об окружающем мире и происходящих изменениях.
- ➡ [Яндекс Вордстат](#) — инструмент, который показывает статистику поисковых запросов к Яндексу. С его помощью можно посмотреть, как менялась популярность интересующих вас запросов и как она отличается в разных регионах России, а также построить топ запросов с нужными словами и узнать, что ещё люди искали на ту же тему.
- ➡ [Портал открытых данных РФ](#) — государственный цифровой ресурс, который собирает, систематизирует и предоставляет структурированную, машиночитаемую информацию о деятельности органов власти для анализа, повторного использования и создания новых сервисов.




Обязательные виды графиков 1 — Линейная диаграмма (построение временного ряда и или множеств значений)

Внимание на ОСИ!!!

Стоимость акций компании Google



Дополнительные значения на уже построенный график выводятся с помощью команды **lines**




```
plot(as.Date(data_3$Date), data_3$Open, type="l", col="blue", panel.first=grid(), xlab = "Номер значения", ylab =  
"Стоимость", main="Стоимость акций компании Google", axes = FALSE)  
axis(1,pos = 100)  
axis(2,pos = 13000)  
arrows(x0 = 13000, x1 = 13000, y0 = 100,y1 = 1200, length = 0.15, angle = 15, xpd = TRUE,lwd=2)  
arrows(x0 = 13000, x1 = 18100, y0 = 100,y1 = 100, length = 0.15, angle = 15, xpd = TRUE,lwd=2)
```



Обязательные виды графиков 2 — Круговая диаграмма

Объем операций с акциями Google




```
x_pie <- c(  
  length(data_3$Volume[data_3$Volume < 5e6]),  
  length(data_3$Volume[data_3$Volume >= 5e6 & data_3$Volume < 10e6]),  
  length(data_3$Volume[data_3$Volume >= 10e6 & data_3$Volume < 15e6]),  
  length(data_3$Volume[data_3$Volume >= 15e6])  
)  
  
labels <- c(  
  "< 5 млн.",  
  "5-10 млн.",  
  "10-15 млн.",  
  "> 15 млн."  
)  
  
pie(x_pie,  
  labels = labels,  
  main = "Объем операций с акциями Google",  
  col = rainbow(length(x_pie)))
```



Обязательные виды графиков 3 — Столбчатая диаграмма (гистограмма – простейший вариант)


Стоимость акций компании Google



Номер значения

```
plot(as.Date(data_3$Date), data_3$Open, type="h",
col="blue", panel.first=grid(), xlab = "Номер значения",
ylab = "Стоимость", main="Стоимость акций компании
Google",axes = FALSE)
axis(1,pos = 100)
axis(2,pos = 13000)
arrows(x0 = 13000, x1 = 13000, y0 = 100,y1 = 1200, length =
0.15, angle = 15, xpd = TRUE,lwd=2)
arrows(x0 = 13000, x1 = 18100, y0 = 100,y1 = 100, length =
0.15, angle = 15, xpd = TRUE,lwd=2)
```

Объем операций с акциями Google



Объем купли/продажи

```
hist(data_3$Volume, main="Объем операций с акциями
Google", xlab = "Объем купли/продажи", ylab = "Число
значений в выборке", axes = FALSE)
axis(1,pos = 0)
axis(2,pos = 0)
arrows(x0 = 0, x1 = 0, y0 = 0,y1 = 2800, length = 0.15,
angle = 15, xpd = TRUE,lwd=2)
arrows(x0 = 0, x1 = 50000000, y0 = 0,y1 = 0, length =
0.15, angle = 15, xpd = TRUE,lwd=2)
```




Обязательные виды графиков 4 — Столбчатая диаграмма (с использованием библиотеки)

#Объединяем данные и строим общий график

```
p_merge <- merge(p22, p23, by = "p1", all.x = TRUE)
p_merge <- merge(p_merge, p22IT, by = "p1", all.x = TRUE)
p_merge <- merge(p_merge, p23IT, by = "p1", all.x = TRUE)
```


```
library(plotly)
```

```
fig <- plot_ly(p_merge, x = ~p1, y=~p2_22, type = 'bar', name = '2022')
fig <- fig %>% add_trace(y = ~p2_23, name = '2023')
fig <- fig %>% add_trace(y = ~p2_IT22, name = '2022 IT')
fig <- fig %>% add_trace(y = ~p2_IT23, name = '2023 IT')
fig <- fig %>% layout(yaxis = list(title = 'Число проектов', 'Регион'), barmode = 'group')
fig
```






Обязательные виды графиков 5 — Скрипичная диаграмма



```
library(vioplot) #Для рисования скрипичной диаграммы  
vioplot(XX1$W, XX2$W, XX3$W, XX4$W, XX5$W, XX6$W, XX7$W, XX8$W, XX9$W,col = "lightgray", panel.first=grid())
```





Дополнительные виды графиков 1 — Графики с выделенными областями)



```
plot(xx,S_R5_mean[10:47], type="l", col="black", panel.first=grid(), ylim = c(0,60), xlab = "Вероятность  
появления заявки", ylab = "Время обработки")  
polygon(c((10:47)/100, (47:10)/100), c(S_R5_mean[10:47]+sqrt(disp5[10:47]), S_R5_mean[47:10]-  
sqrt(disp5[47:10])), col="black", border=NA, density = 20, angle = 45)  
polygon(c((10:47)/100, (47:10)/100), c(S_R3_mean[10:47]+sqrt(disp3[10:47]), S_R3_mean[47:10]-  
sqrt(disp3[47:10])), col="blue", border=NA, density = 20, angle = 315)
```



Дополнительные виды графиков 2 — Построение поверхностей




```
z2<-matrix(NA, nrow = 30, ncol = 30)
for (i1 in 1:30) {
  for (i2 in 1:30) {
    z2[i1,i2]<-res$s2_mean[res$s1_prob==i1/30 & res$s2_prob==i2/30]
  }
}

x<-(1:30)/30
y<-(1:30)/30

persp(x, y, z2, xlab="\n\nP(S1)", ylab="\n\nP(S2)", zlab="\n\nСреднее время для S2", col = "lightgray", shade = 0.4, theta=-45, phi=30, ticktype="detailed")
```



Дополнительные виды графиков 3 — Трехкомпонентные диаграммы



```
#install.packages("Ternary")
library("Ternary")

setwd("/Users/leonid/Documents/ВШЭ/Рейтинг_ESG/Статья")
results_all<-read.csv("results.csv", header =T, sep = ",", encoding = "UTF-8")

results_all_1<-data.frame(E=results_all$env, S=results_all$social, G=results_all$gov,
N=results_all$on_letters)
results_all_1<-results_all_1[order(results_all_1$N, decreasing=FALSE),]
results_all_1<-as.matrix(results_all_1)


length(results_all_1[,1])

spectrumBins <- 1220
mySpectrum <- viridisLite::viridis(spectrumBins)

binnedReflectance <- cut(results_all_1[1:1220,4], spectrumBins)

pointCol <- mySpectrum[binnedReflectance]

TernaryPlot(alab = "E", blab = "S", clab = "G",
            grid.lines = 3,grid.lty = "dotted",
            grid.minor.lines = 1, grid.minor.lty = "dotted")
TernaryPoints(results_all_1[1:1220,1:3], cex = results_all_1[1:1220,4]*1.5,
              col = pointCol, pch = 16)
```




$$S_{ABC} = S_{PAB} + S_{PBC} + S_{PCA}$$
$$\frac{1}{2} h S = \frac{1}{2} p S + \frac{1}{2} m S + \frac{1}{2} n S$$
$$h = p + m + n$$

Дополнительные виды графиков 3 — Трехкомпонентные диаграммы

Винченцо Вивиани - итальянец живший в XVII века, который впервые заметил, что в равностороннем треугольнике при выборе в нём произвольной точки сумма высот получившихся трех треугольников равняется высоте исходного треугольника.

!!! Выражение никоим образом не зависит от положения точки P внутри треугольника!

Этот факт позволит использовать теорему Вивиани как основу для создания трехкомпонентных диаграмм, в зависимости от области применения называющихся треугольниками Гиббса (описание водно-солевых систем), диаграммами де Финетти (популяционная генетика), диаграммой воспламеняемости и др.




Примеры:

- 1) С помощью трехкомпонентной диаграммы можно классифицировать почву по национальным стандартам (например, суглинок и т.д.)?
- 2) С помощью трехкомпонентной диаграммы, определяется цвет золота в зависимости от состава сплава.



Дополнительные виды графиков 4 — Построение карт



```
library(sp)
library(maptools)
library(rgdal)
library(pals)

#Рисование Пермского края
setwd("/Users/leonid/Documents/Для Елоховой")
Perm_data<- read.csv("Perm_region.csv", header =T, sep = ";", encoding
= "UTF-8")
Perm_data<-Perm_data[order(Perm_data$N),]
nc2<-
readShapePoly("gadm36_RUS_shp/gadm36_RUS_3.shp",proj4string=CRS("+proj=
longlat +datum=NAD27"))
Perm<-nc2[grepl("Perm",nc2$NAME_1),]


# добавляем к координатам сведения
Perm@data$LQ1<-Perm_data$LQ1

myPalette<-brewer.oranges(20)[4:20]

spplot(Perm, "LQ1", col.regions=myPalette, main="Perm Region LQ1",
lwd=0.8, par.settings = list(axis.line = list(col = NA)))
```



Дополнительные виды графиков 5 — Построение карт



```
library(rgdal)
shpfile <-
readOGR(dsn="/Users/leonid/Documents/БШЭ/СП4/geoBou
ndaries-RUS-ADM1-all",layer = "geoBoundaries-RUS-ADM1")
proj4.str <- CRS("+init=epsg:3413 +lon_0=105")
nc1_2 <- spTransform(shpfile,CRS=proj4.str,
verbose=TRUE)
nc1_2@data$res<-pm$p2.y
my.Palette <- bpy.colors(130)
spplot(nc1_2, "res", colorkey = list(space =
"bottom"),lwd=.1, col="white")
```



Дополнительные виды графиков 6 — Лепестковые или радарные диаграммы



La selección de Portugal ha pasado de tener uno de los plantillos más jóvenes a generar alguno que crea duda por las bajas de Pepe en defensa, la posible salida de Nuno Mendes, y Diego Jota y Neto en ataque. No obstante, Cristiano Ronaldo, Bruno Fernandes, Bernardo Silva y Cancelo son rivales para crear.



Si siempre tiene tanta fama como Uruguay o Portugal, Ghana viene para poner en serio apuros al grupo y como objetivo tiene lo ocurrido en el Mundial de Sudáfrica de 2010. Con Thomas Partey como líder, la experiencia de los hermanos Agyei y la novedad Naah Williams son el peligro.



El entrenador, Ronald Araújo, entró, tras su lesión, solamente en la fase de Uruguay. En ataque, más lejos que nunca tras perder con su hermano la liga uruguaya. Luc Suñeriz volverá a ser el gran referente. El mediocista Fede Valverde es una gran estrella de la nueva selección de Diego Alonso, mezcla de generaciones.



Corea del Sur es una selección articulada en torno a su gran estrella, el extremo del Tottenham Heung-min Son. A la velocidad que tradicionalmente ha tenido el conjunto coreano, Paulo Bento, su seleccionador desde 2018, ha añadido orden táctico. Su problema, que a veces deja espacios.


См. пакет fmsb или radarchart и команду radarchart()



Дополнительные виды графиков 7 — лица Чернова

Лица Чернова (Chernoff Faces) - это схема визуального представления многофакторных данных в виде человеческого лица. Каждая часть лица: нос, глаза, рот - представляет собой значение определенной переменной, назначенной для этой части: так можно изобразить большой массив из 20-переменных в виде простого и понятного всем изображения. Математик Герман Чернов предположил в 70-ые годы, что лица людей это всегда хорошо воспринимаемый и запоминаемый паттерн и предложил использовать в качестве рабочего инструмента построения пиктограмм.

Принцип композициональности — значение сложного выражения есть функция значений его частей и того способа, каким они соединены синтаксически.



Проблема такого отображения данных в том, что обычно это булевы - 0 и 1, где вместо 0 - пустой зрачок, а 1 графическое изображение огромного яркого зрачка. Все реальные данные будут отображаться между этими промежутками на лице, что рисует своеобразного гомункулуса. Анализ информации при помощи такого способа отображения основан на способности человека интуитивно находить сходства и различия в чертах лица.



Статистический анализ одномерных выборок

Математическое ожидание – это значение случайной величины, которое она принимает в среднем. Можно сказать, что это среднее арифметическое всей генеральной совокупности значений случайной величины. Обозначается $M(X)$ или $M[X]$.

Мода – значение случайной величины, которое она принимает с наибольшей вероятностью (самое часто встречающееся значение). Обозначается Mo .

Если таких значений несколько, то распределение называется полимодальным (многомодальным).

Медиана – это значение, делящее упорядоченную генеральную совокупность значений пополам, т.е. половина элементов меньше (не больше) медианы, а половина – больше (не меньше). Обозначается Me .



Статистический анализ одномерных выборок

Среднее геометрическое (среднее пропорциональное) — такое число, которым можно заменить каждое из этих чисел так, чтобы их произведение не изменилось

$$x_{geom} = (x_1 \cdot x_2 \cdot x_3 \cdot \dots \cdot x_n)^{1/n} = (\prod_{i=1}^n x_i)^{1/n}$$

Среднее гармоническое — обратная величина к среднему от обратных чисел (является средним степени -1)

$$\min(x_1, \dots, x_n) \leq x_{har} \leq \max(x_1, \dots, x_n)$$

$$\frac{n}{x_{har}} = \frac{1}{x_1} + \frac{1}{x_n}.$$

$$x_{har} = \frac{1}{\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i}} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}.$$

Если $B_n = B_0 \cdot x_1 \cdot \dots \cdot x_n$ фактор роста то он может быть вычислен как $B_n = B_0 \cdot (x_{geom})^n$

Примером может быть вычисление среднего ускорения.

Например если мы имеем производственную линию длиной l и каждая операция выполняется со скоростью $x_1, x_2, \dots, x_n$ тогда время обработки будет равно $\frac{1}{x_1} + \frac{1}{x_2} + \dots + \frac{1}{x_n}$, а среднее время обработки на линии x_{har} .



Статистический анализ одномерных выборок

Дисперсия – величина, характеризующая разброс значений случайной величины около математического ожидания $M(X)$. Обозначается $D(X)$ или $D[X]$ или σ^2 .

Вычисляем величину дисперсии по формуле $D = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - M(X))^2$

Стандартное (средне квадратичное) отклонение – квадратный корень из дисперсии. Характеризует среднее абсолютное отклонение значений от их мат. ожидания. Обозначается $\sigma = \sqrt{D(X)}$.

Коэффициент вариации (относительное стандартное отклонение) – величина, характеризующая среднее относительное отклонение значений от мат. ожидания. Обозначается V , измеряется в процентах.

$$V = \frac{\sigma}{M(X)}$$



Статистический анализ одномерных выборок

Квантиль в математической статистике — значение, которое заданная случайная величина не превышает с фиксированной вероятностью. Если вероятность задана в процентах, то квантиль называется процентилем или перцентилем.

Для каждого значения x_p с вероятностью $0 < p < 1$ существует такое значение вероятности p которое удовлетворяет отношению меньше/равные значению x_p и значение вероятности $1 - p$ которое удовлетворяет отношению больше/равные значению x_p . Такое значение x_p называют p квантилем. Из этого следует

$$\frac{\text{Число значений } x \leq x_p}{n} \geq p \text{ и } \frac{\text{Число значений } x \geq x_p}{n} \geq 1 - p$$


Первым или **нижним квантилем** называют 25% квантиль — $x_{0.25}$

Третьим или **верхним квантилем** называют 75% квантиль — $x_{0.75}$

50% квантиль — $x_{0.50}$ называют медианой


Статистический анализ одномерных выборок

Box-Plot диаграмма (ящик с усами, диаграмма размаха, усиковая диаграмма, коробчатая диаграмма, блочная диаграмма с ограничителями выбросов)



Для того что бы построить box-plot диаграмму необходимо определить ряд характеристик:

- 25% (первый) квартиль $Q_{25} = x_{\frac{1}{4}n}'$,
- 50% квартиль (медиану) $Q_{50} = x_{\frac{1}{2}n}'$,
- 75% (третий) квартиль $Q_{75} = x_{\frac{3}{4}n}'$,
- значения минимума,
- максимума,
- значение межквартильного интервала (Interquartile range) $IQR = Q_{75} - Q_{25}$
- значения 5% и 95% квартилей (Q_5 и Q_{95}).





Интерполяционная формула Лагранжа

Пусть функция $f(x)$ задана таблицей. Построим интерполяционный многочлен $L_n(x)$, степень которого не больше n . Будем искать $L_n(x)$ в виде:

$$L_n(x) = l_0(x) + l_1(x) + \dots + l_n(x).$$

где $l_i(x_k)$ — многочлен степени n , задаваемый следующей функцией:

$$l_i(x) = \begin{cases} y_i, & i = k; \\ 0, & i \neq k. \end{cases}$$

Многочлены составим следующим способом:

$$l_i(x) = c_i(x - x_0) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n),$$

где c_i — постоянный коэффициент, значение которого найдем из первой части условия:

$$c_i = \frac{y_i}{(x_i - x_0) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n)}$$

Подставив в предыдущее выражение и далее в выражение для $L_n(x)$, окончательно получаем:

$$L_n(x) = \sum_{i=0}^n y_i \cdot \frac{(x - x_0) \dots (x - x_{i-1})(x - x_{i+1}) \dots (x - x_n)}{(x_i - x_0) \dots (x_i - x_{i-1})(x_i - x_{i+1}) \dots (x_i - x_n)}$$



Жозеф Луи Лагранж
25.01.1736 (Турин) -
10.04.1813 (Париж)
(Французский математик
итальянского
происхождения)

Интерполяционный
многочлен
Лагранжа




Интерполяционная формула Лагранжа (пример)

По таблично заданной функции приведенная формула позволяет составить "внешний вид" многочлена.

x	1	3	4
f(x)	12	4	6

Для таблично заданной функции, приведенной в таблице $n = 2$ (т. е. степень многочлена будет не выше, чем вторая), $x_0 = 1, x_1 = 3, x_2 = 4$. Используя интерполяционную формулу Лагранжа, получаем:


$$L_2 = 12 \cdot \frac{(x - 3)(x - 4)}{(1 - 3)(1 - 4)} + 4 \cdot \frac{(x - 1)(x - 4)}{(3 - 1)(3 - 4)} + 6 \cdot \frac{(x - 1)(x - 3)}{(4 - 1)(4 - 3)}.$$





Интерполяционная формула Лагранжа (особенность)

Средняя сумма заявок на ипотечный кредит за период с 2013 по 2018 год



Черная линия - многочлен
Лагранжа


Зеленая линия - соединённые
отрезками точки



Интерполяция сплайнами

Интерполяционную кривую можно построить очень простым способом, если последовательно соединить точки заданного набора значений отрезками. В результате получится ломаная линия. При использовании такого способа интерполяции n точек требуется найти всего $(n - 1)$ чисел (каждый прямолинейный отрезок определяется ровно двумя коэффициентами прямой). Однако построенная таким образом аппроксимирующая кусочно-линейная функция не обладает гладкостью (первая производная этой функции терпит разрывы в узлах стыка полученных прямых).

Подход, основанный на интерполяции сплайнами, — это попытка найти класс функций, которые сохранили бы простоту построения описывающей данные модели (особенно невысокую степень используемых многочленов) и при этом в результате применения давали гладкую функцию.





Интерполяция сплайнами

Для этого будем использовать многочлены и строить интерполяционную функцию последовательно, звено за звеном. В результате получится так называемый **полиномиальный многозвенник**. При таком подходе важно правильно выбрать степени привлекаемых многочленов, а для гладкости получаемой кривой необходимо тщательно подобрать коэффициенты многочленов (из условий гладкого сопряжения соседних звеньев). Результат применения такого подхода называют **сплайн-функциями** или **сплайнами**.

Интерполяционным кубическим сплайном, называется функция $S(x)$, обладающая следующими свойствами:

- график этой функции проходит через каждую точку заданного набора точек $S(x_i) = y_i, \forall i$;
- на каждом из отрезков $[x_i, x_{i+1}]$, $i = 1, \dots, n - 1$ функция является многочленом третьей степени

$$S(x) = \sum_{j=1}^3 a_j^{(i)} (x - x_i)^j;$$

- на всем отрезке задания $[x_0, x_n]$ функция $S(x)$ имеет непрерывную вторую производную.

ПРИМЕР!




Интерполяция сплайнами

При использовании многочленов третьей степени на каждом из отрезков $[x_i, x_{i+1}]$ сплайн-функция $S(x)$ полностью определяется четырьмя коэффициентами. Для полного построения на всей области заданных значений необходимо найти $4 \cdot (n - 1)$ чисел.

Используя вышеприведенные условия, получим $n + n - 2$ уравнений, если приравнять значения составляющих функций значениям точек, через которые они проходят, и еще $n - 2$ уравнения из равенства первых и $n - 2$ уравнения из равенства вторых производных во всех внутренних точках, что вместе составляет $n + n - 2 + n - 2 + n - 2 = 4 \cdot n - 6$ равенства.

Недостающие два уравнения для полного определения коэффициентов можно получить, задав значения первых производных на концах отрезка (граничные условия): $S'(x_0) = 1$, $S'(x_n) = 1$. Могут использоваться граничные условия и других типов.

В результате получаем разрешимую систему, из которой находим значения всех коэффициентов многочленов.






Сравнение методов


Инфляция в России за 2016 год

Месяц	1	2	3	4	5	6	7	8	9	10	11	12
% инфляции	0,96	0,63	0,46	0,44	0,41	0,36	0,54	0,01	0,17	0,43	0,44	0,4


Линейная интерполяция



Сплайн 3-го порядка



Функция Лагранжа





Статистические показатели

Если планируется делать обобщения и использовать модель на разных данных, то необходимы множественная проверка результатов модели на различных данных и использование оценки точности, такие как:

MAE (mean absolute error — средняя абсолютная ошибка): $\frac{1}{n} \sum_{j=1}^n |y_i - y_i^*|$

RMSE (root mean square error — среднеквадратичная ошибка): $\sqrt{\frac{1}{n} \sum_{j=1}^n (y_i - y_i^*)^2}$

MAPE (mean percentage absolute error — средняя абсолютная ошибка в процентах): $\frac{1}{n} \sum_{j=1}^n \frac{|y_i - y_i^*|}{y_i} \cdot 100\%$

MASE (mean absolute scaled error — средняя абсолютная масштабированная ошибка): $\frac{MAE}{\frac{1}{n-1} \sum_{j=2}^n |y_j - y_{j-1}|}$

