



Факультет социально-экономических и
компьютерных наук

Кафедра информационных
технологий в бизнесе

Пермь
2026

Задание 2

Регрессионный анализ

**(использование экстраполяции в задачах
прогнозирования значений временных рядов)**



Базовая часть (полное выполнение — 8 баллов)

- 1) Используя выбранный файл данных из предыдущей работы построить функцию для прогнозирования последующих значений выбранного параметра на основе его предыдущих значений. Для этого выбрать не менее 100 его последовательных значений, разбить их на 2 интервала (80 % значений – тренировочная выборку и 20 % значений – тестовая выборка) и используя первые 80 % значений спрогнозировать значения последующих 20 % с использованием: а) **модели ARIMA**, б) **k-NN / скользящего среднего**.
- 2) Постройте на тех же данных используя методы **МНК** и **SVM (SVR)** однопараметрические регрессионные модели. При использовании метода МНК используйте модель $y=c_0+c_1*x$.
- 3) Усложните модели полученные на предыдущем шаге дополнив их еще одним параметром (регрессионная модель с двумя параметрами) из выбранного файла данных. Для МНК используйте функцию $y=c_0+c_1*x_1+c_2*x_2$.
- 4) Постройте графики значений получаемых с использованием всех моделей и нанесите на них значения из тестовой и тренировочной выборок.
- 5) Сравните точность моделей визуально и с использованием метрик **MAE**, **RMSE**. Сделайте выводы о том насколько хорошие результаты показали модели, а также о наблюдаемых закономерностях.

Дополнительная часть:

+1 балл


- 1) Используйте свой файл данных со значениями параметров в форме **временных рядов** (без повторов между одноклассниками на потоке);
- 2) Постройте многопараметрические регрессионные модели с использованием методов Lasso и PLS.
- 3) Сравните полученные результаты с результатами полученными в обязательной части задания, добавьте сравнение с использованием метрики **R2**, сделайте выводы.

+2 балла


- 1) Исследуйте влияние размера обучающей выборки сначала вдвое увеличив, а затем вдвое сократив её размер от исходного значения.
- 2) Усложните многопараметрические модели добавляя на каждом шаге предыдущее значения искомого параметра (расчетное значение предыдущего шага для вычисления последующего).
- 3) Провести сравнение полученных результатов.



Classification



Regression



Estimated
(or predicted)
Y value for
observation i

Estimate of
the regression
intercept

Estimate of the
regression slope

Value of X for
observation i


$$\hat{Y}_i = b_0 + b_1 X_i$$



Задача регрессии (аппроксимации)


Процедура замены функции $f(x)$ на функцию $g(x)$ называется **аппроксимацией**.

- задача **интерполяции** позволяет определить z — значение функции в точке, находящейся внутри исследуемого интервала $[a; b]$ и $z \in [a, b], z \neq x_i, i = 1, \dots, n$;
- задача **экстраполяции** позволяет определить значение функции в точке, находящейся вне исследуемого интервала $[a; b]$ и $z \notin [a, b]$.



Регрессионный анализ — набор статистических методов исследования влияния одной или нескольких независимых переменных ($x_1, x_2, \dots, x_n$) на зависимую переменную (y^*). Независимые переменные иначе называют **регрессорами** или **предикторами**, а зависимые переменные — **критериальными** или **регрессантами**.

Прогноз на заданный горизонт планирования (на $>$ чем 1 шаг)



- 1) Прогнозные значения используем как «реальные» для следующего шага.
- 2) Делаем прогноз для каждого из параметров модели.



Модели стационарных временных рядов (AR(p) - модель)

Прогноз представляет собой сумму предыдущих значений с некоторыми коэффициентами, которые являются постоянными и определяют параметры модели авторегрессии, а также порядок модели авторегрессии (p - количество предыдущих периодов из прошлого, которые мы будем использовать для прогнозирования (например, если на вход модели будем подавать значения за три предыдущих интервала (за три предыдущих дня), а прогнозировать значение в следующий период (сколько будет продано на следующий день), то порядок модели $p = 3$)). Кратко это часто записывается как AR(3):

$$Y(t) = a_0 + a_1Y(t-1) + a_2Y(t-2) + a_3Y(t-3) + \varepsilon(t),$$

где a - коэффициенты (параметры модели); Y - значения предыдущих этапов; ε - случайная ошибка (случайное воздействие).

В общем виде авторегрессионная (AR) модель записывается как

$$Y(t) = a_0 + \sum_{i=1}^p a_i \cdot Y(t-i) + \varepsilon(t)$$

Ошибка/
погрешность

Идея авторегрессии состоит в использовании для получения новых (прогнозных) значений предыдущих значений.

Применение AR-модели предполагает обязательную стационарность исследуемого ряда.

Такая модель может интерпретироваться как линейная модель множественной регрессии, в которой в качестве переменных выступают прошлые значения самой зависимой переменной.



Модели стационарных временных рядов (MA(q) и ARMA(p,q) модели)

Для моделирования случайной ошибки используют модель скользящего среднего (MA)

$$Y(t) = \sum_{j=1}^q b_j \cdot \varepsilon(t - j),$$

где q - порядок модели; ε - последовательность независимых и одинаково распределённых случайных величин (как правило, нормальных) с нулевым средним.

Добавив моделирование случайной ошибки в AR модель получим модель скользящего среднего (ARMA). Модель ARMA обобщает две приведенные выше модели. Моделью ARMA(p, q), где p и q - целые числа, задающие порядок модели, называется следующий процесс генерации временного ряда:

$$Y(t) = a_0 + \varepsilon(t) + \sum_{i=1}^p a_i \cdot Y(t - i) + \sum_{j=1}^q b_j \cdot \varepsilon(t - j).$$

Текущее наблюдение в модели скользящего среднего представляет собой сумму случайной компоненты в данный момент времени и линейной комбинации случайных воздействий в предыдущие моменты времени.



Модель проинтегрированного скользящего среднего (ARIMA(p,q,d) модель или модель Бокса-Дженкинса)

Модель ARIMA(p, d, q) означает, что разности временного ряда порядка d подчиняются модели ARMA(p, q). В общем виде модель авторегрессии и проинтегрированного скользящего среднего описывается формулой

$$\Delta^d Y(t) = a_0 + \epsilon(t) + \sum_{i=1}^p a_i \cdot \Delta^d \cdot Y(t-i) + \sum_{j=1}^q b_j \cdot \epsilon(t-j),$$

где Δ^d - оператор разности временного ряда порядка d (последовательное взятие d раз разностей первого порядка - сначала от временного ряда, затем от полученных разностей первого порядка, затем от второго порядка и т.д.).

$\Delta = 1 - L$, где L - лаговый оператор. Разность первого порядка может быть вычислена по формуле $\Delta Y(t) = (1 - L)Y(t) = Y(t) - Y(t-1)$. Разность второго порядка может быть вычислена по формуле $\Delta^2 Y(t) = \Delta(\Delta Y(t)) = (1 - L)^2 Y(t) = (1 - 2L + L^2)Y(t) = Y(t) - 2Y(t-1) + Y(t-2)$. В общем виде $\Delta^d Y(t) = \Delta(\Delta^{d-1} Y(t)) = (1 - L)^d Y(t)$.

Нестационарность обычно проявляется в наличии зависящей от времени неслучайной составляющей $f(t)$. Для описания таких рядов используется модель авторегрессии проинтегрированного скользящего среднего (ARIMA).

ARIMA -интегрированная модель авторегрессии является расширением моделей ARMA для нестационарных временных рядов, которые можно сделать стационарными взятием разностей некоторого порядка от исходного временного ряда.

Модель ARIMA интерпретируется как ARMA(p+d, q) - модель с d единичными корнями. При $d=0$ имеем обычные ARMA-модели.



Метод наименьших квадратов

В результате проведенного эксперимента пусть мы имеем набор точек (x_i, y_i) , $i = 1 \dots m$, причем $x_i \neq x_j$ при $i \neq j$ и значения y_i содержат ошибки измерения. Мы хотим через данные точки провести кривую $F(x)$, которая является линейной комбинацией заранее выбранных базисных функций $f_j(x)$, $j = 1 \dots n$. Другими словами,

$$F(x) = \sum_{j=1}^n c_j f_j(x).$$

Часто в качестве базисных функций рассматривают мономы $f_j(x) = x^{j-1}$. Коэффициенты c_j необходимо определить, выбрав определенный критерий для сравнения функций. Рассмотрим критерий, называемый МНК. Построим матрицу значений базисных функций в заданных точках

$$A = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \vdots & \ddots & \vdots \\ f_1(x_m) & \dots & f_n(x_m) \end{pmatrix}.$$

Матрица A , как правило, не будет квадратной матрицей. Пусть $\mathbf{c}$ – вектор из n искомых коэффициентов. Тогда можно построить вектор из m значений, через которые проходит данная кривая:

$$\mathbf{y}^* = A \cdot \mathbf{c} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \vdots & \ddots & \vdots \\ f_1(x_m) & \dots & f_n(x_m) \end{pmatrix} \cdot \begin{pmatrix} c_1 \\ \dots \\ c_n \end{pmatrix} = \begin{pmatrix} F(x_1) \\ \dots \\ F(x_m) \end{pmatrix}.$$



Метод наименьших квадратов

Для минимизации величины отклонения искомой кривой от заданных нам точек потребуем, чтобы коэффициенты вектора $\mathbf{c}$ определялись минимумом «расстояния» между векторами $\mathbf{y}$ и $\mathbf{y}^*$, т.е. чтобы было выполнено условие

$$\left(\sum_{i=1}^m (y_i - y_i^*)^2 \right)^{1/2} \rightarrow \min$$

(евклидова норма). Другими словами, мы хотим, чтобы сумма квадратов разностей между экспериментальным и теоретическим значением была минимальной (после возведения в квадрат левой и правой частей неравенства), отсюда и название **МНК**

$$\sum_{i=1}^m (y_i - y_i^*)^2 \rightarrow \min.$$

Как правило, в литературе выводятся формулы для случая линейного и квадратичного приближения. Мы рассмотрим более общий алгоритм, пригодный для любого выбора базисных функций. Чтобы найти минимум функции, необходимо продифференцировать ее по всем переменным $\mathbf{c}_k$ и приравнять соответствующие производные нулю. Тогда мы получим систему уравнений, которую можно записать в виде

$$\frac{\partial (\sum_{i=1}^m (y_i - y_i^*)^2)}{\partial (c_k)} = \sum_{i=1}^m 2 \left(\sum_{j=1}^n a_{ij} c_j - y_i \right) a_{ik} = 0, k = 1 \dots n.$$



Метод наименьших квадратов

Полученное уравнение в математической статистике называется **нормальным уравнением**. Можно показать, что матрица $A^T A$ является симметрической и, согласно теории матриц, если ее столбцы являются линейно независимыми, существует обратная матрица $(A^T A)^{-1}$. Тогда решение системы относительно неизвестного вектора c является единственным и выражается формулой

$$c = \left((A^T A)^{-1} A^T \right) y = A^+ y.$$

Матрица $A^+ = (A^T A)^{-1} A^T$ называется псевдообратной матрицей по аналогии с обратной матрицей для систем алгебраических линейных уравнений.



Метод k-NN в задачах регрессии (простое скользящее среднее)

При решении задачи регрессии методом kNN параметром модели является количество ближайших соседних точек k , используемых для получения новых значений.


Например, если нам необходимо оценить значение y_7 в точке x_7 , то берем значения y ближайших k предшествующих x_7 точек и вычисляем значение

$$y_7 = \frac{\sum_{i=1}^k y_i}{k}.$$


Процесс обучения сводится к подбору значения k , которое будет давать наилучший результат, для чего можно использовать различные методы.

Метод кросс-проверки.

Весь набор данных разбивается на n равных по размеру блоков, затем последовательно каждый из блоков используется для обучения, а результат проверяется на следующем за ним блоке. Очевидно, что может принимать значение от 2 до K , где K — количество значений в наборе данных. В результате такой проверки выбирается n , дающее усредненный наилучший результат по точности прогнозирования по одному из критериев согласия. Значение в результате определяем по формуле $k = \frac{K}{n}$.



SVM в задачах регрессии (SVR - support vector regression)



Поставим задачу линейной регрессии:

$$f(x) = \sum_{j=1}^N w_j \cdot x_j + b$$

w – коэффициенты перед параметрами, величина вектора нормали к аппроксимирующей поверхности, N – число признаков.

SVR ставит цель найти такую линию (или гиперплоскость в многомерном пространстве), чтобы **максимальное количество точек данных лежало внутри "трубы" (эпсилон-полосы) вокруг этой линии**, а не на самой линии. Т.е. найти такую функцию $f(x)$, чтобы как можно больше точек y_i (реальных значений параметра) лежало внутри этой полосы:

$$|y_i - f(x_i)| \leq \epsilon$$

Смысл SVR в том, чтобы найти баланс:

- фиксируем ϵ (например, 0.1).
- ищем w , который минимизирует $\|w\|$ (делает функцию гладкой) и минимизирует сумму штрафов $\sum \zeta_i$ (пытается подогнать точки, вылетающие за пределы трубки).

Точки внутри полосы считаются правильно предсказанными, **их ошибка** $|y_i - f(x_i)| < \epsilon$ а **штраф** (ζ_i и ζ_i^*) **равен нулю**. SVR их просто игнорирует. **Опорными векторами** становятся только те точки, которые лежат **за пределами** эпсилон-полосы (нарушают условие $|y_i - f(x_i)| \leq \epsilon$) или лежат **на границе** эпсилон-полосы.



SVM в задачах регрессии (SVR - support vector regression)

Окончательно получаем задачу на оптимизацию:

$$\frac{1}{2} \|w\|^2 + c \cdot \sum_{i=1}^N (\zeta_i + \zeta_i^*) \rightarrow \min,$$

регуляризация **+** **штраф за ошибки**

$$y_i - w^T \cdot x_i \leq \varepsilon + \zeta_i^*, i = 1, \dots, N; \quad (\text{верхняя граница})$$
$$w^T \cdot x_i - y_i \leq \varepsilon + \zeta_i, i = 1, \dots, N; \quad (\text{нижняя граница})$$
$$\zeta_i, \zeta_i^* \geq 0, i = 1, \dots, N.$$

$\|w\|$ минимизируют чтобы
максимизировать ширину
полосы (зазор) и избежать
переобучения.

где $\|w\|$ — норма вектора (норма — длина вектора весов (L) в пространстве признаков; минимизация $\|w\|^2$ делает функцию более плоской и гладкой (регуляризация));

ζ_i и ζ_i^* — переменные ослабления (slack variables), которые измеряют, насколько сильно точка нарушает эпсилон-полосу;


c — штраф за ошибку (он контролирует компромисс между шириной эпсилон-полосы (игнорирование небольших ошибок); суммой отклонений точек, выходящих за её пределы (чем меньше c , тем слабее штраф за выход точек за пределы полосы. Модель может позволить себе оставить больше точек вне трубки, что дает более простую (сглаженную) функцию и может привести к недообучению; чем больше c , тем строже модель наказывается за выход за пределы полосы, что заставляет её сильнее подстраиваться под выбросы и может привести к переобучению);

ε — это гиперпараметр, который мы задаем сами перед обучением (мы не оптимизируем его в процессе говоря модели: «Я хочу, чтобы ты игнорировала ошибки меньше ε », это настройка пользователя (насколько мы доверяем данным); если мы скажем $\varepsilon = \infty$, мы скажем модели: «Игнорируй всё» и модель вырождается).

* Введение этих переменных и параметра необходимо т.к. часто невозможно найти линию, чтобы все точки лежали внутри эпсилон-полосы т.к. данные могут быть зашумленными.

SVM в задачах регрессии (SVR - support vector regression)

Задача оптимизации SVR, которую мы рассмотрели на предыдущем слайде, соответствует минимизации **ϵ -нечувствительной функции потерь** (график а). Однако могут применяться и другие типы функций потерь, которые используются в регрессии. Например, (b) - квадратичная ϵ -нечувствительная потеря; (c) – потеря Хубера



$$L_{\epsilon}(y, f(x, w)) = \begin{cases} 0, & |y - f(x, w)| \leq \epsilon; \\ |y - f(x, w)|, & \text{в других случаях.} \end{cases}$$


$$L_{\epsilon}(y, f(x, w)) = \begin{cases} c|y - f(x, w)| - \frac{c^2}{2}, & |y - f(x, w)| > c; \\ \frac{1}{2}|y - f(x, w)|^2, & |y - f(x, w)| \leq c. \end{cases}$$

$$L_{\epsilon}(y, f(x, w)) = \begin{cases} 0, & |y - f(x, w)| \leq \epsilon; \\ (|y - f(x, w)|)^2, & \text{в других случаях.} \end{cases}$$




Понятие недообучения и переобучения применительно к временным рядам

Проверка на адекватность - не проходит
Прогностический свойства - плохие




Недообученная модель

Проверка на адекватность - проходит
Прогностический свойства - хорошие



Обученная модель

Проверка на адекватность - проходит на
тренировочных данных но не проходит на
тестовых
Прогностический свойства - плохие



Переобучения модель



Коэффициент детерминации

$$R^2 = \frac{\sum_{i=1}^n (y_i^* - M(y))^2}{\sum_{i=1}^n (y_i - M(y))^2} = 1 - \frac{\sum_{i=1}^n (y_i - y_i^*)^2}{\sum_{i=1}^n (y_i - M(y))^2}$$

$$0 \leq R^2 \leq 1, R^2 = r_{XY}^2$$

Коэффициент детерминации (R^2 — R-квадрат) — это доля дисперсии зависимой переменной, объясняемая рассматриваемой моделью зависимости, то есть объясняющими переменными. Более точно — это единица минус доля необъяснённой дисперсии (дисперсии случайной ошибки модели, или условной по факторам дисперсии зависимой переменной) в дисперсии зависимой переменной. Его рассматривают как универсальную меру зависимости одной случайной величины от множества других. В частном случае линейной зависимости R^2 является квадратом так называемого множественного коэффициента корреляции между зависимой переменной и объясняющими переменными. В частности, для модели парной линейной регрессии коэффициент детерминации равен квадрату обычного коэффициента корреляции между y и y^* .

