Факультет социально-экономических и компьютерных наук

Кафедра информационных технологий в бизнесе

Пермь
2025

Задание 4

Методы классификации (повышение эффективности их работы)

Шаг1: Базовая часть (полное выполнение — 8 баллов)

1.1) Продолжите работу с файлами и результатами полученными при выполнении третьего задания (если используете свои файлы данных то продолжайте с ними работать).
1.2) При использовании методов kNN, SVM, Logistic Regression выполните k-fold кросс-валидацию (k=5) и сравните качество полученных результатов с результатами полученными на предыдущем этапе с использованием метрик (Accuracy, F мера, LogLoss, ROC кривая, Confusion Matrix)
1.3) Реализуйте композицию моделей kNN, SVM, Logistic Regression используя Hard Voting и Soft Voting. Сравните качество полученных результатов с предыдущими результатами (используйте тот же набор метрик).
1.4) Реализуйте метод AdaBoost с одним из методов деревьев решений в качестве базового алгоритма. Сравнить полученные результаты с предыдущими.

Дополнительная к базовой часть :

Шаг 2: +1 балл
2.1) Увеличьте объем данных за счет генерации подобных значений (upsampling) путем создания искусственных значений и доведя его таким образом до равного числа количество значений в рассматриваемых классах.
2.2) Повторите обучение моделей kNN, SVM и сравните с полученными ранее результатами используя предложенный набор метрик.
2.3) Дополнительно к реализованным опробуйте метод стэкинга (stacking) для создания композиции моделей.

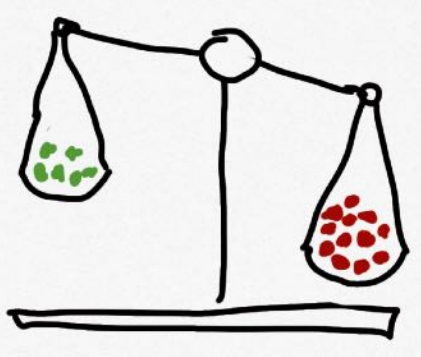
Шаг 3: еще +1 балл (итого +2 балла к базовой части)
3.1) Предложите правило разбиения данных на части и реализуйте для с их использованием метод бэггинга.
3.2) Увеличьте число используемых моделей до 5 за счет Naïve Bayes, C4.5/5.0, CART, или LDA.
3.4) Сравните используя метрики получение результаты с результатами полученными на предыдущих шагах.

Сбалансированные и не сбалансированные выборки

Пример 1. Идентификация спама.
Пусть у нас будет 100 писем из которых 90 спам тогда получается, что модель которая все письма помечает как спам даёт 90% угадывания.

Не сбалансированными называют выборки данных в которых количество одних типов данных значительно превышает другие

Пример 2. Медицинская диагностирующая система.
При простановке диагноза в зимнее время если всем ставить диагноз ОРВИ то процент угадывания будет очень большой.



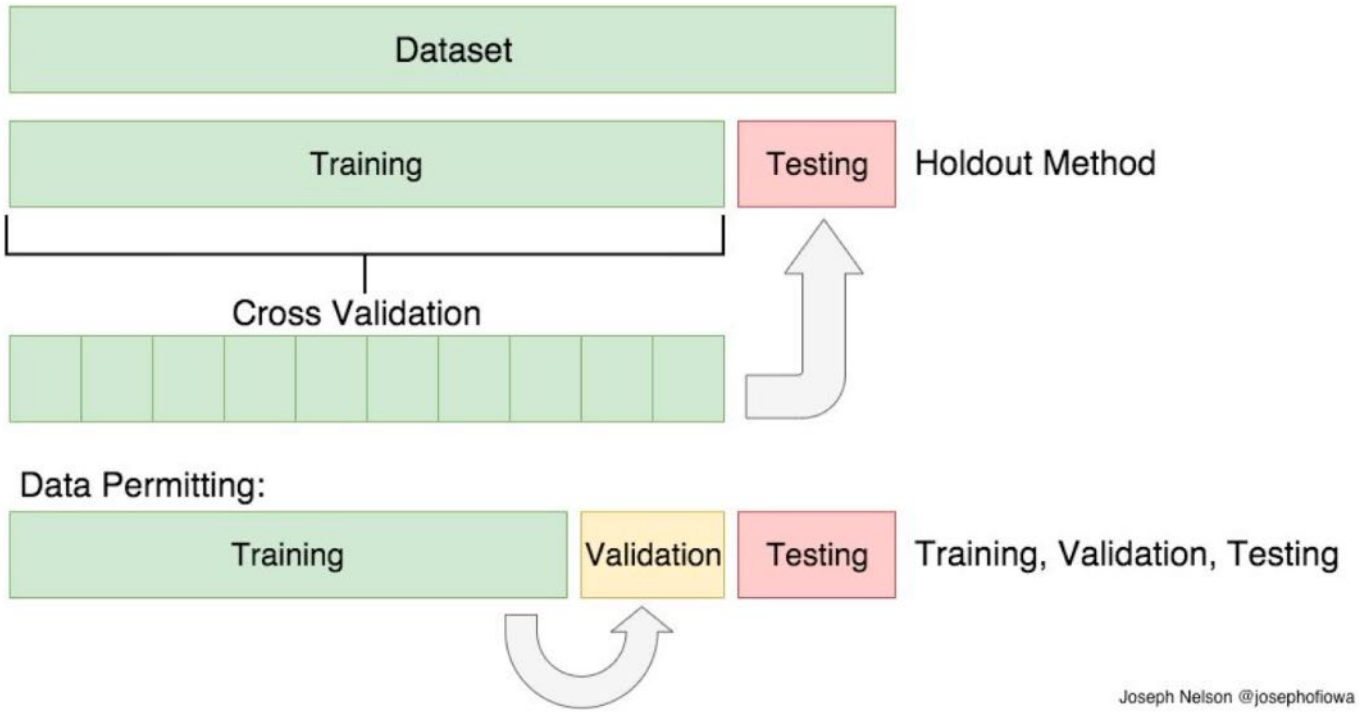


Image credit: Joseph Nelson @josephofiowa

Кросс валидация

Валидация на отложенных данных (Hold-Out Validation)

Обучающая выборка один раз случайным образом разбивается на две части

$$T_l = T_t \cup T_{l-t},$$

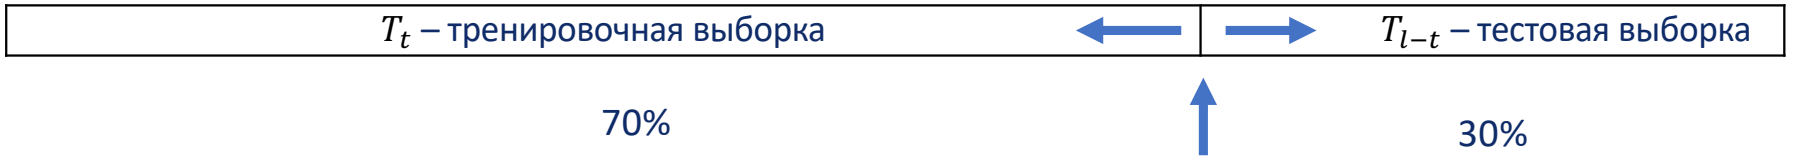
где t – место разбиения, а l – число элементов в выборке.

После этого решается задача оптимизации

$$Hold - Out\left(\mu, T^l, T^{l-t}\right) = Quality(\mu(T^t), T^{t-l}) \to opt,$$

где μ – метод ML.

Данный метод применяется на больших датасетах, т.к. требует меньше вычислительных ресурсов по сравнению с другими кросс-валидациями. Недостатком является то, что оценка существенно зависит от разбиения, тогда как желательно, что бы она характеризовала только алгоритм обучения.



Кросс валидация

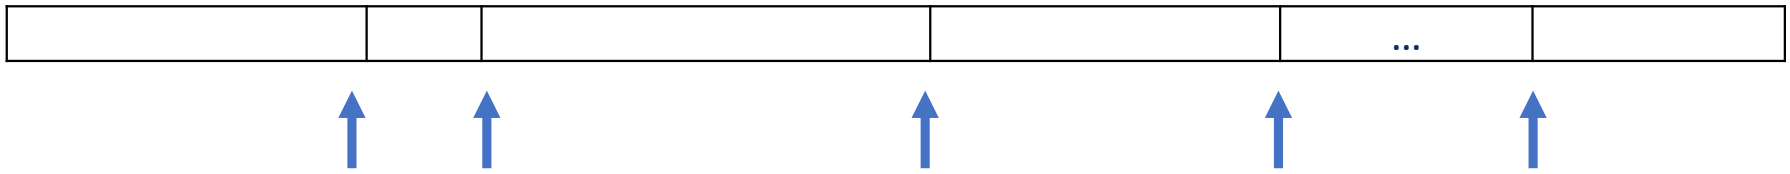
Полная кросс-валидация (Complete Cross-Validation)

1) Выбирается значение t.
2) Выборка разбивается всеми возможными способами на две части $T^l = T^t \cup T^{l-t}$

После этого решается задача оптимизации

$$Complete\ Cross-Validation_t = \frac{1}{C_l^{l-t}} \sum_{T^l = T^t \cup T^{l-t}} Quality(\mu(T^t), T^{t-l}) \to opt$$

Здесь число разбиений C_l^{l-t} становиться слишком большим даже при сравнительно малых значениях t, что затрудняет практическое применение данного метода.



Кросс валидация

K-fold кросс-валидация

1)Обучающая выборка разбивается на $\boldsymbol{k}$ не пересекающихся одинаковых по объему частей.
2)Производится $\boldsymbol{k}$ итераций. На каждой итерации происходит следующее:

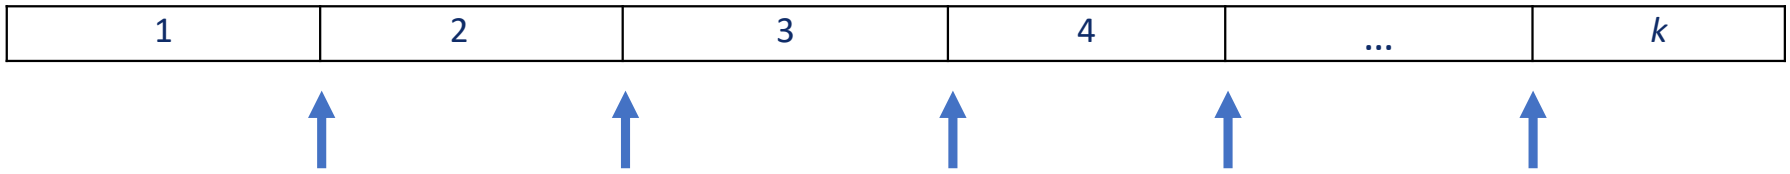
a) Модель обучается на $\boldsymbol{k-1}$ части обучающей выборки

b) Модель тестируется на части обучающей выборки, которая не участвовала в обучении.

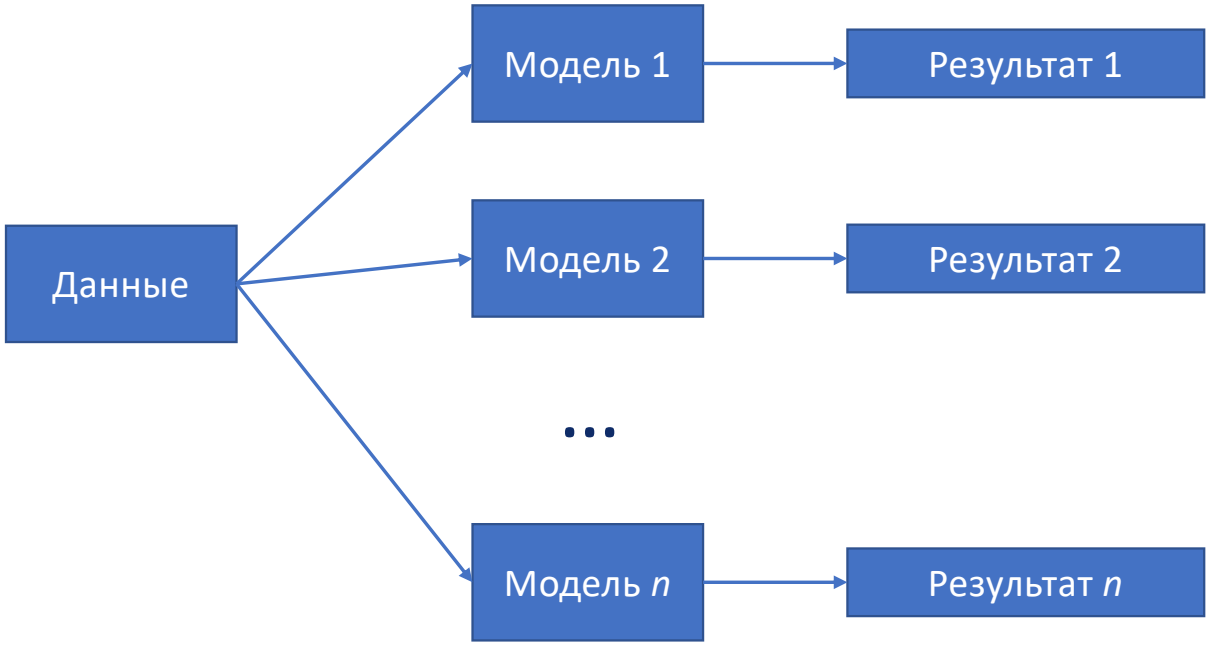
Каждая из $\boldsymbol{k}$ частей единожды используется для тестирования.

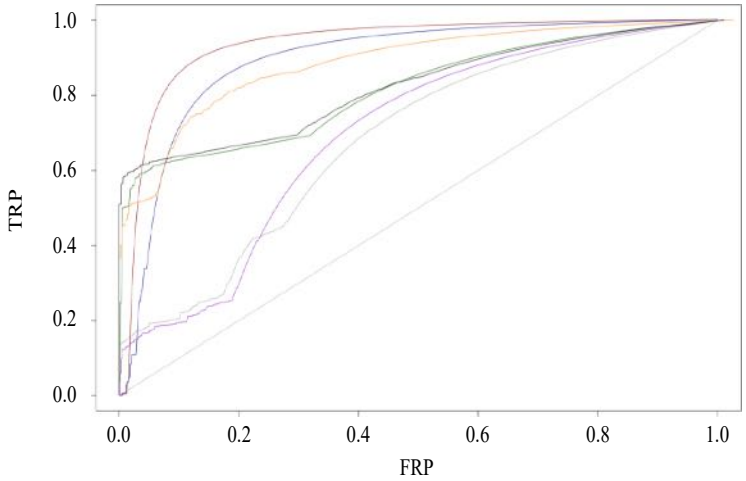
$$\boldsymbol{T^l = F1 \cup \ldots \cup F_k, F_i \approx \frac{1}{k},}$$

$$\boldsymbol{CV_k = \frac{1}{k} \sum_{i=1}^{k} Q(\mu(T^l \setminus F_i), F_i) \rightarrow min}$$



Ансамблирование/композиция моделей





Ансамблирование/композиция моделей

- Воттинг (**Voting**). Рассматриваются разные модели, результаты которых потом усредняются.
- Бэггинг (**Bagging**). Рассматриваются одинаковые модели обученные на разных данных (частях данных). Результаты которых потом усредняются.
- Бустинг (**Boosting**). Рассматриваются однородные модели, которые обучаются последовательно, причем последующая модель должна исправлять ошибки предыдущей. Конечно, в качестве примера здесь сразу приходит на ум градиентный бустинг и AdaBoost
- Стекинг (**Stacking**). Могут рассматриваться разнородные отдельно взятые модели. Существует мета-модель, которой на вход подаются базовые модели, а выходом является итоговый прогноз.

Воттинг (пример)

Пример работы алгоритма объединения моделей на основе значений класса (hard)

model 1	model 2	model 3	model 4	…	model 15
0	1	0	0	…	0
0	0	0	0	…	0
1	0	1	0	…	1
1	0	1	0	…	0
1	1	0	0	…	1
0	1	0	0	…	1
0	0	0	0	…	1
…	…	…	…	…	…

sum	sum>7?	fraud
1	0	0
0	0	0
8	1	0
9	1	1
12	1	1
3	0	0
2	0	0
…	…	…

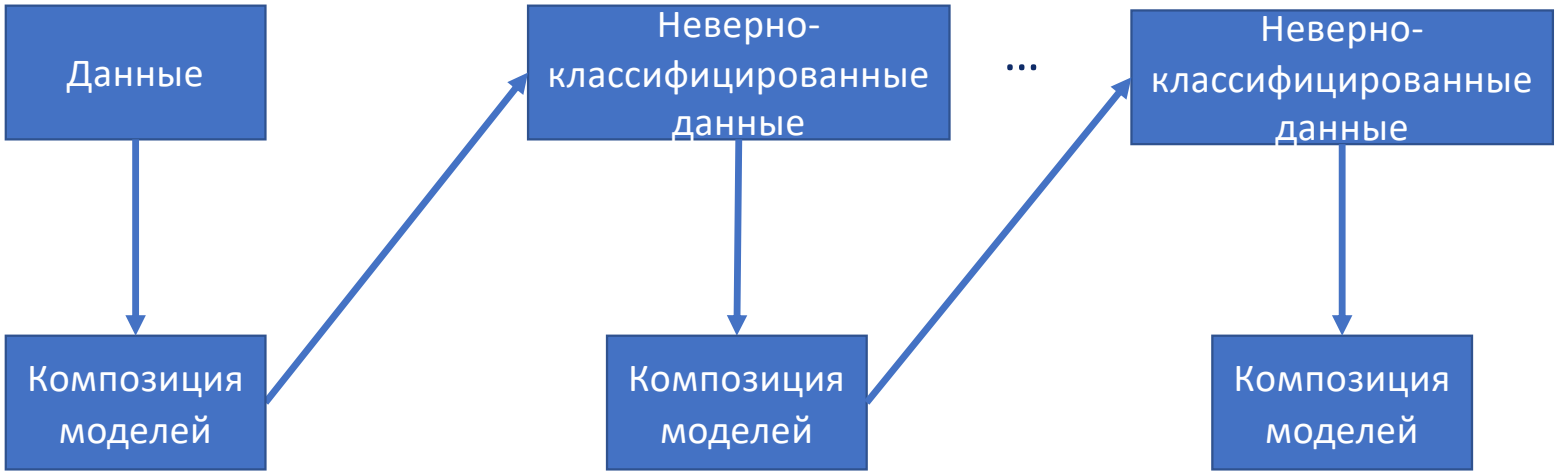
Пример работы алгоритма объединения моделей на основе вероятностей принадлежности к 1 классу (soft)

model 1	model 2	model 3	model 4	…	model 15
0.0001	0.9941	0.0002	0.0001	…	0.0001
0.0023	0.0011	0.0019	0.0001	…	0.0231
0.9563	0.0001	0.8216	0.0001	…	0.9999
0.9648	0.0013	0.9245	0.0001	…	0.0001
0.8976	0.7489	0.0034	0.0001	…	0.8952
0.0002	0.8988	0.0077	0.0001	…	0.9112
0.0016	0.0014	0.0358	0.0001	…	0.9655
…	…	…	…	…	…

prob sum	prob sum>0.8?	fraud
0.1541	0	0
0.6587	0	0
0.6411	0	0
0.8869	1	1
0.9746	1	1
0.3651	0	0
0.4321	0	0
…	…	…

Бустинг

Бустинг – это метод преобразования слабо-обученных моделей в хорошо-обученные. В бустинге каждый новый шаг использует модифицированную версии исходного датасета.



AdaBoost (адаптивный бустинг)

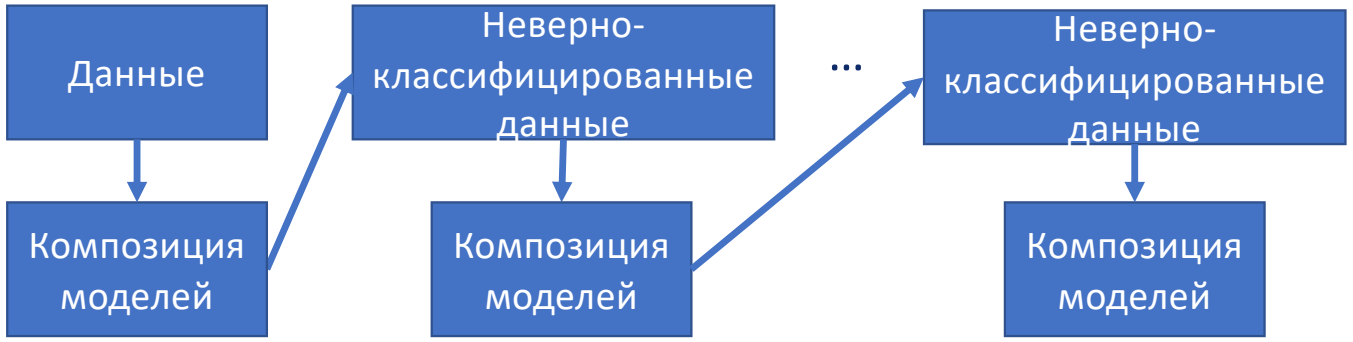
AdaBoost обучает модель, в которой каждому наблюдению присваивается вес. После оценки модели увеличиваются веса тех наблюдений, которые сложно классифицировать, и уменьшаются веса тех, которые легко классифицировать. Следующее модель опирается на эти скорректированные веса. Таким образом, текущую модель можно обозначить как *Модель 1 + Модель 2*. Затем подсчитывается ошибка этой модели и создается следующая модель для выдачи новых предсказаний. Этот процесс продолжается столько раз, сколько указано. Последующие модели помогают нам классифицировать наблюдения, которые плохо классифицируются предыдущими моделями. В результате прогнозы окончательной ансамблевой модели представляют собой взвешенную сумму прогнозов, сделанных предыдущими деревьями.

$$F_T(x) = \sum_{t=1}^{T} f_t(x)$$

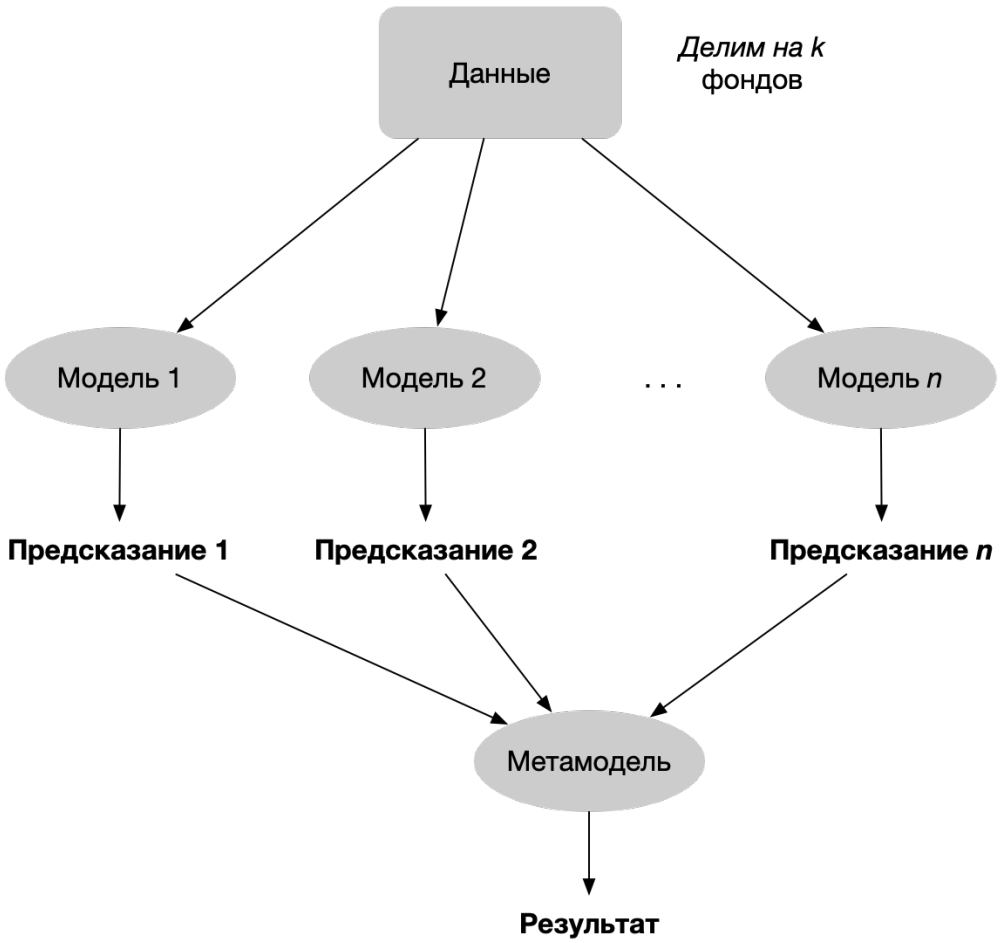
где x — классифицируемые данные,
f_t — слабый классификатор

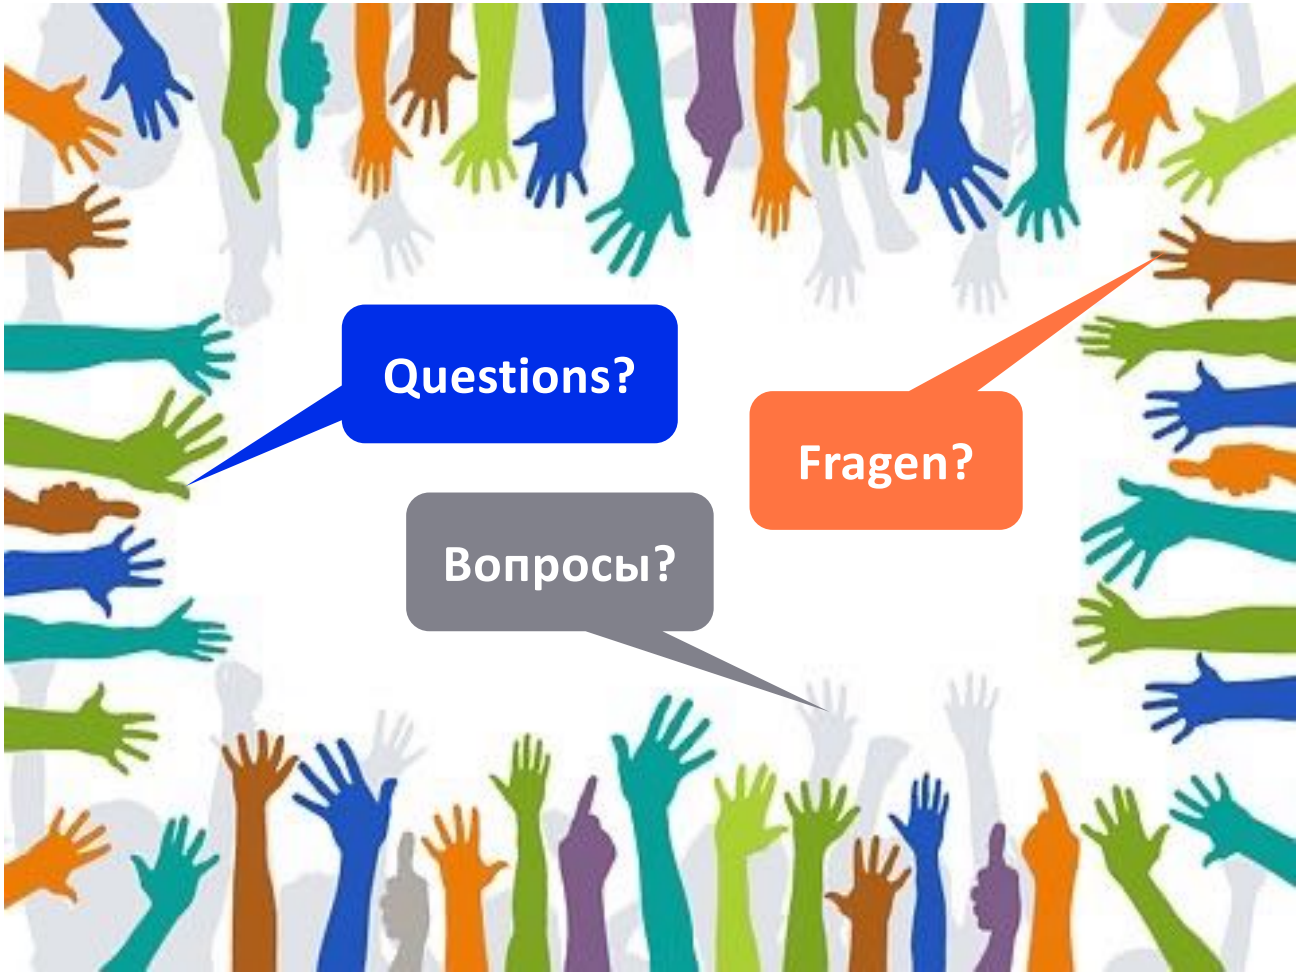
$$E_t = \sum_i E[F_{t-1}(x_i) + \alpha_t h(x_i)]$$

где E — ошибка, F_{t-1} — классификатор отобранный на предыдущем шаге, $f_t(x)=\alpha_t h(x)$



Стеккинг


Данные
Делим на k фондов
Модель 1
Модель 2
. . .
Модель *n*
Предсказание 1
Предсказание 2
Предсказание *n*
Метамодель
Результат


Questions?
Fragen?
Вопросы?